

1 Théorie

The data are derived from the observation of a statistical sample of n vectors in \mathbb{R}^{p+1} :

$$(Z_i^1, \dots, Z_i^p, Y_i) \quad i = 1, \dots, n.$$

On cherche à expliquer une variable quantitative Y_i (réponse) par p variables Z_i^1, \dots, Z_i^p dites *variables explicatives* (ou encore *régresseurs*).

On pose $\theta := (\beta_1, \dots, \beta_p, \sigma^2) \in \Theta := \mathbb{R}^p \times \mathbb{R}_+^*$. Le *modèle linéaire* consiste à supposer que, pour tout $\theta \in \Theta$, les variables

$$\varepsilon_i(\theta) := \sigma^{-1} \{Y_i - (\beta_1 Z_i^1 + \dots + \beta_p Z_i^p)\}, \quad i = 1, 2, \dots, n,$$

sont des variables indépendantes et identiquement distribuées. Il est plus pratique dans ce cas de représenter le modèle sous la forme matricielle

$$\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \sigma\boldsymbol{\varepsilon}(\theta), \quad (1)$$

où

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad \boldsymbol{\beta} := \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \boldsymbol{\varepsilon}(\theta) := \begin{bmatrix} \varepsilon_1(\theta) \\ \vdots \\ \varepsilon_n(\theta) \end{bmatrix}, \quad \mathbf{Z} := \begin{bmatrix} Z_1^1 & \dots & Z_1^p \\ Z_2^1 & \dots & Z_2^p \\ \vdots & & \vdots \\ Z_n^1 & \dots & Z_n^p \end{bmatrix};$$

\mathbf{Y} est le vecteur des observations, $\boldsymbol{\beta}$ est le vecteur des paramètres de régression et \mathbf{Z} est la matrice de régression de taille $n \times p$.

1.1 Estimation par moindres carrés du vecteur $\boldsymbol{\beta}$

Pour estimer le paramètre $\boldsymbol{\beta} \in \mathbb{R}^p$ dans le modèle de régression linéaire, la *méthode des moindres carrés* consiste à chercher un estimateur $\hat{\boldsymbol{\beta}} \in \mathbb{R}^p$ qui minimise le risque quadratique empirique i.e. minimise la fonction

$$\begin{aligned} \mathbf{u} \mapsto J_n(\mathbf{u}) &:= \sum_{i=1}^n (Y_i - u_1 Z_i^1 - \dots - u_p Z_i^p)^2 \\ &= \sum_{i=1}^n (Y_i - \mathbf{Z}_i^T \mathbf{u})^2 = \|\mathbf{Y} - \mathbf{Z}\mathbf{u}\|^2, \quad \text{où } \mathbf{u} := \begin{bmatrix} u_1 \\ \vdots \\ u_p \end{bmatrix}. \end{aligned}$$

1. Montrer que toute solution $\hat{\mathbf{u}} \in \arg \min_{\mathbf{u} \in \mathbb{R}^p} J_n(\mathbf{u})$ est solution des *équations d'estimation* en $\mathbf{u} \in \mathbb{R}^p$:

$$\mathbf{Z}^T \mathbf{Y} = \mathbf{Z}^T \mathbf{Z} \mathbf{u}.$$

Nous supposons dans la suite que les hypothèses de *Gauss-Markov* sont vérifiées :

GM1 $n > p$ et la matrice \mathbf{Z} est de rang p .

GM2 les erreurs de régression sont *homoscédastiques*, pour tout $\theta \in \Theta$, $\mathbb{E}_\theta[\boldsymbol{\varepsilon}(\theta)] = 0$ et $\text{Var}_\theta(\boldsymbol{\varepsilon}(\theta)) = \mathbf{I}_n$.

Notons que l'hypothèse (GM1) implique que la matrice de Gram $\mathbf{Z}^T \mathbf{Z}$ est inversible et l'hypothèse (GM2) entraîne que pour tout $\theta \in \Theta$

$$\mathbb{E}_\theta [\mathbf{Y}] = \mathbf{Z}\boldsymbol{\beta}, \quad \text{Var}_\theta [\mathbf{Y}] = \sigma^2 \mathbf{I}_n.$$

Nous posons

$$\mathbf{Z}^\# := (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T,$$

qui est appelée la *pseudo-inverse* de \mathbf{Z} .

2. Montrer que $\mathbf{Z}^\# \mathbf{Z} = \mathbf{I}_p$ et $\mathbf{Z} \mathbf{Z}^\# = \mathbf{H}$ où \mathbf{H} est le projecteur orthogonal sur l'espace vectoriel engendré par les colonnes de la matrice \mathbf{Z} .
3. Montrer que l'estimateur des moindres carrés est unique et a pour expression :

$$\hat{\boldsymbol{\beta}} := (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} = \mathbf{Z}^\# \mathbf{Y}. \quad (2)$$

L'estimateur $\hat{\boldsymbol{\beta}}$ est dit *linéaire*, car il est obtenu en calculant une combinaison linéaire des observations Y_1, \dots, Y_n .

4. Montrer que l'estimateur des moindres carrés est un estimateur sans biais de $\boldsymbol{\beta}$.
5. Montrer que pour tout $\theta \in \Theta$, la matrice de covariance de cet estimateur est donnée par :

$$\text{Var}_\theta(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}. \quad (3)$$

Soit \mathbf{B} une matrice déterministe de taille $p \times n$; on pose $\tilde{\boldsymbol{\beta}} := \mathbf{B} \mathbf{Y}$.

6. Montrer que l'estimateur $\tilde{\boldsymbol{\beta}}$ est sans biais si et seulement si $\mathbf{B} \mathbf{Z} = \mathbf{I}_p$.

Dans la suite du problème, nous supposons que $\mathbf{B} \mathbf{Z} = \mathbf{I}_p$.

7. Montrer que pour tout $\theta \in \Theta$,

$$\mathbb{E}_\theta \left[(\tilde{\boldsymbol{\beta}} - \boldsymbol{\beta})(\tilde{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \right] = \sigma^2 \mathbf{B} (\mathbf{Z}^\#)^T = \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}.$$

Noter que cette quantité est la matrice de covariance $\text{Cov}_\theta(\tilde{\boldsymbol{\beta}}, \tilde{\boldsymbol{\beta}})$.

Si A et B sont deux matrices symétriques $p \times p$, nous notons $A \succeq B$ si et seulement si, pour tout $x \in \mathbb{R}^p$, $x^T A x \geq x^T B x$.

8. Montrer que pour tout $\theta \in \Theta$, $\text{Var}_\theta(\tilde{\boldsymbol{\beta}}) \succeq \text{Var}_\theta(\hat{\boldsymbol{\beta}})$.

En conclusion, nous venons d'établir que l'estimateur des moindres carrés de $\boldsymbol{\beta}$ est

$$\hat{\boldsymbol{\beta}} := (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}.$$

C'est un estimateur sans biais, de variance $\sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}$. Il est de variance minimale dans la classe des estimateurs sans biais et linéaires.

1.2 Estimation de la variance σ^2 et Coefficient de détermination

Nous appelons $\hat{\mathbf{Y}} := \mathbf{Z}\hat{\boldsymbol{\beta}}$ la *prédiction* des observations \mathbf{Y} . En observant que $\mathbf{Z}\hat{\boldsymbol{\beta}} = \mathbf{H}\mathbf{Y}$, la prédiction $\hat{\mathbf{Y}}$ est la projection orthogonale de \mathbf{Y} sur l'espace engendré par les colonnes de la matrice de régression \mathbf{Z} . Nous appelons les *résidus de régression* les composantes du vecteur

$$\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}} = \mathbf{Y} - \mathbf{Z}(\mathbf{Z}^T\mathbf{Z})^{-1}\mathbf{Z}^T\mathbf{Y} = (\mathbf{I}_n - \mathbf{H})\mathbf{Y}. \quad (4)$$

Considérons la statistique définie comme la somme des carrés des résidus (appelée *Sum of Squared Errors of prediction* ou *SSE* dans la littérature anglo-saxonne) :

$$\text{SSE} := \|\mathbf{Y} - \mathbf{H}\mathbf{Y}\|^2. \quad (5)$$

9. En observant que pour tout vecteur $w \in \mathbb{R}^\ell$, on a $\text{Tr}(w w^T) = \|w\|^2$, montrer que

$$\hat{\sigma}^2 := (n - p)^{-1} \text{SSE} = \frac{1}{n - p} \|\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}}\|^2$$

est un estimateur sans biais de la variance σ^2 .

Considérons finalement la somme des carrés de régression (ou *régression sum of squares*, RSS) :

$$\text{RSS} := \|\mathbf{H}\mathbf{Y}\|^2. \quad (6)$$

10. Montrer que

$$\|\mathbf{Y}\|^2 = \text{RSS} + \text{SSE}. \quad (7)$$

En conclusion, l'estimateur

$$\hat{\sigma}^2 := \frac{1}{n - p} \|\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}}\|^2$$

est un estimateur sans biais de σ^2 . De plus, le *coefficient de détermination* défini par

$$R^2 := \frac{\text{RSS}}{\|\mathbf{Y}\|^2}$$

est un nombre dans $[0, 1]$, qui représente la part de variation de \mathbf{Y} expliquée par le modèle de régression.

1.3 Cas de la régression linéaire gaussienne

On suppose maintenant que \mathbf{Y} est l'observation canonique d'un modèle gaussien

$$(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \{N_n(\mathbf{Z}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n) : \boldsymbol{\theta} = (\boldsymbol{\beta}, \sigma^2) \in \mathbb{R}^p \times \mathbb{R}_+^*\}).$$

11. Déterminer l'estimateur du maximum de vraisemblance du paramètre $\boldsymbol{\theta}$.

12. Pour tout $\boldsymbol{\theta} \in \Theta$, déterminer la distribution de l'estimateur des moindres carrés $\hat{\boldsymbol{\beta}}$ sous $\mathbb{P}_{\boldsymbol{\theta}}$.

13. Pour tout $\boldsymbol{\theta} \in \Theta$, déterminer la distribution de $\hat{\sigma}^2$ sous $\mathbb{P}_{\boldsymbol{\theta}}$.

14. Pour tout $\theta \in \Theta$, montrer que $\hat{\beta}$ et $\hat{\sigma}^2$ sont indépendants sous \mathbb{P}_θ .

En conclusion, dans le cas où les erreurs de régression sont gaussiennes, l'estimateur de β par moindres carrés et celui par maximum de vraisemblance coïncident. L'estimateur par maximum de vraisemblance de σ^2 est un estimateur biaisé. Enfin, les deux estimateurs $\hat{\beta}$ et $\hat{\sigma}^2$ sont indépendants et sous \mathbb{P}_θ , nous avons

$$\hat{\beta} \sim N_p(\beta, \sigma^2(\mathbf{Z}^T \mathbf{Z})^{-1}) \quad , \quad (n-p) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-p).$$

1.4 Tests statistiques, cas régression linéaire gaussienne

15. Soit $\mathbf{x} \in \mathbb{R}^p$. Montrer que sous \mathbb{P}_θ ,

$$\frac{\mathbf{x}^T \hat{\beta} - \mathbf{x}^T \beta}{\hat{\sigma} \sqrt{\mathbf{x}^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{x}}}$$

suit une loi de Student à $(n-p)$ degrés de liberté.

16. Soit $\alpha \in]0, 1[$. Déterminer un intervalle de confiance bilatéral de niveau de couverture $1 - \alpha$ pour $\beta^T \mathbf{x}$.
17. Soit $\alpha \in]0, 1[$. Construire un test de l'hypothèse

$$H_0 : \beta^T \mathbf{x} = 0, \quad \text{contre} \quad H_1 : \beta^T \mathbf{x} \neq 0$$

de niveau α .

18. Déterminer la p -valeur de ce test.
19. Soit A une matrice de taille $q \times p$ de rang $q \leq p$. Montrer que sous \mathbb{P}_θ ,

$$\frac{1}{q\hat{\sigma}^2} \{A(\hat{\beta} - \beta)\}^T [A(\mathbf{Z}^T \mathbf{Z})^{-1} A^T]^{-1} \{A(\hat{\beta} - \beta)\}$$

suit une loi de Fisher à $(q, n-p)$ degrés de liberté.

20. Déterminer une région de confiance pour le vecteur (β_1, β_2) (on a posé $\beta = [\beta_1, \dots, \beta_p]^T$).

2 Pratique

La variable à expliquer est la concentration en ozone notée **O3** et les variables explicatives sont la température notée **T12**, le vent noté **Vx** et la nébulosité notée **Ne12**. Nous rajouterons dans la matrice de régression le vecteur constant $(1, \dots, 1)^T$ que nous appelons **intercept**.

1. Estimer l'estimateur des moindres carrés du paramètre.
2. Déterminer les intervalles de confiance bilatères à 95% pour chaque valeur des paramètres.
3. Visualiser les régions de confiance à 95 % pour (β_1, β_2) et (β_1, β_3) .

Nous cherchons à répondre aux questions suivantes :

- (i) est-ce que la valeur de $O3$ est influencée par Vx ?
 - (ii) y a-t-il un effet nébulosité ?
 - (iii) est-ce que la valeur de $O3$ est influencée par Vx ou $T12$?
4. Formuler les différentes questions comme des tests d'hypothèses.
 5. Construire des procédures de tests pour ces trois hypothèses.
 6. Conclure.